Système de recommandation d'images de peintures

Rapport projet – (Tâches 1 à 6)

Formation : 4ICS

Module : Traitement Données Massives

Participants :

- Tomy Rulliat
- Erwan Aouchiche
- Loris Monegat

Date : 24 février 2026

Table des matières

1. Introduction 3
2. Collecte de données 3
3. Méthodologie 4
4. Résultats 6
5. Limites et travaux futurs 8
6. Conclusion 8

1. Introduction

- **Objectif du projet**

L'objectif du projet est de concevoir un système de recommandation d'images capable de proposer à chaque utilisateur des œuvres en rapport avec ses préférences.

Concrètement, le système s'appuie sur des données ouvertes pour constituer un ensemble d'images de peintures, décrit par un ensemble de métadonnées et de caractéristiques calculées, puis apprend à mettre en correspondance ces caractéristiques avec des profils d'utilisateurs simulés afin de préconiser des recommandations adaptées à l'utilisateur.

- **Approche sur le projet**

Le travail se base sur la collecte et la normalisation des données (via Wikidata/Wikimedia Commons), l'étiquetage (couleurs dominantes, orientation, catégorie de taille, tags issus des métadonnées), l'exploration statistique, la modélisation de profils d'utilisateurs, puis la recommandation par le contenu.

L'enjeu était de mobiliser les acquis des séances pratiques (extraction, visualisation, apprentissage) sur un cas concret et de fournir un projet fonctionnel.

2. Collecte de données

- **Sources des images et licences**

Les images proviennent de Wikimedia Commons et sont référencées via Wikidata (requêtes SPARQL). Les informations de licence (propriété P275 dans Wikidata, lorsqu'elle est présente) sont collectées et conservées avec l'URL d'origine pour assurer la traçabilité. Quand la licence n'est pas explicitement fournie par Wikidata, la page Wikimedia Commons sert de preuve (domaine public ou licence Creative Commons).

- **Nombres d'images collectées**

La requête initiale identifie environ 500 peintures avec image associée. Puis 100 images sont téléchargées et traitées intégralement. L'arborescence suit le sujet : images/ pour les fichiers binaires et data/ pour les fichiers JSON (métadonnées, annotations, profils).

- **Métadonnées stockées**

Pour chaque image, nous stockons : l'ID Wikidata, le titre, le créateur, l'« inception » (date/période), le mouvement, les sitelinks, l'URL de l'image, l'URL source, le nom de fichier local, le format, la taille (en Ko), la largeur/hauteur et les EXIF s'ils existent.

À cela s'ajoutent les annotations calculées par notre programme : orientation (paysage/portrait/carré), catégorie de taille (vignette/moyenne/grande), couleurs dominantes (valeurs RGB + noms FR) et tags (mouvement, créateur, époque, plus un tag générique peinture).

3. Méthodologie

- **Approche d'étiquetage**

Pour la couleur, nous échantillonnons l'image puis appliquons KMeans (k=5) afin d'extraire cinq teintes dominantes. Les RGB sont ensuite convertis en noms de couleurs français (ex. gris foncé, kaki) pour l'interprétation, tout en conservant les valeurs RGB pour la précision.

L'orientation vient du ratio largeur/hauteur (paysage, portrait, carré). La taille est classée en trois niveaux selon la dimension max : vignette (< 500 px), moyenne (500–1500 px), grande (> 1500 px).

Les tags (mouvement, créateur, époque) sont déduits des métadonnées. Des contrôles simples (dimensions positives, champs manquants = inconnu) sont appliqués.

Le résultat final est sauvegardé dans data/images_labels.json.

- **Construction du profil utilisateur**

Nous simulons 5 utilisateurs, chacun avec environ 15 favoris. À partir de ces favoris, nous construisons un profil qui retient :

- les couleurs préférées (top 3) à partir des noms issus de KMeans
- l'orientation et la taille majoritaires
- les tags dominants (en excluant le tag générique peinture)

Les profils sont stockés dans data/users.json.

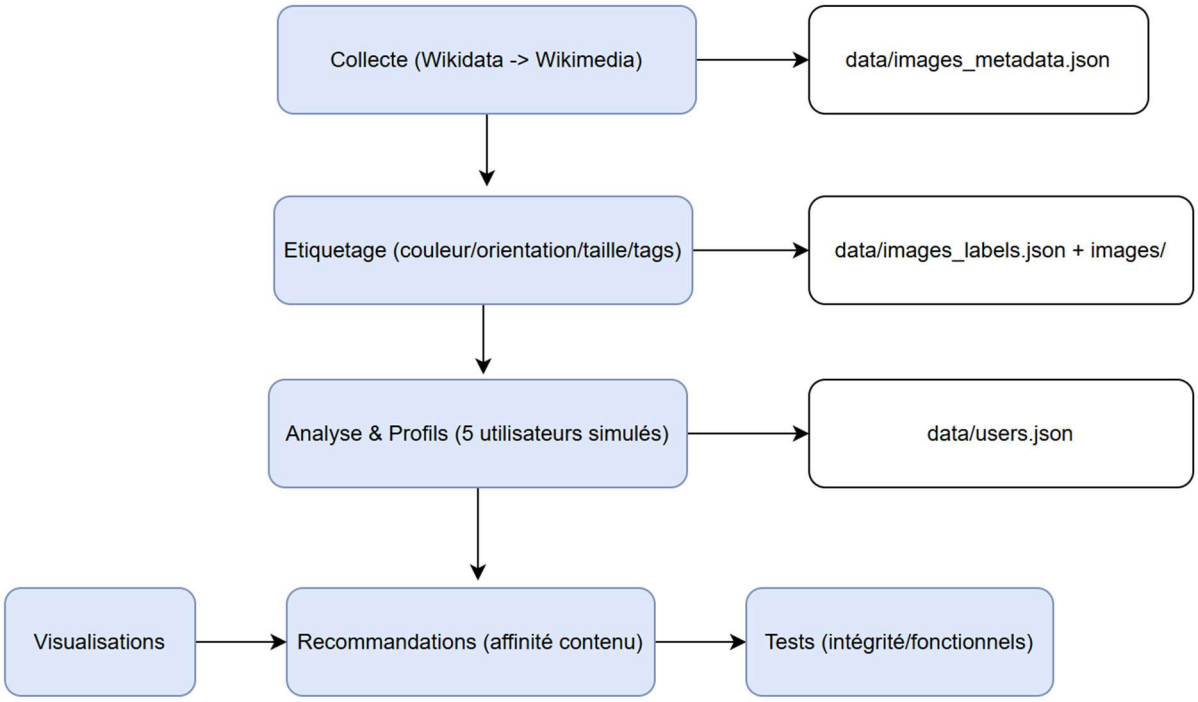
- **Algorithme de recommandation choisi et pourquoi**

Nous avons choisi une approche hybride : un score de contenu (classifieur RandomForest) que l'on a combiné avec un score de proximité grâce aux clusters via KMeans (n=8).

Le score final fusionne les deux (alpha=0.6) puis exclut les images déjà en favoris.

Ce choix donne des recommandations pertinentes, explicables (tags/couleurs/orientation + cluster proche), tout en restant simple à mettre en œuvre et à utiliser par la suite.

- **Inclure un diagramme d'architecture**



4. Résultats

- **Visualisations principales (2-3 figures)**

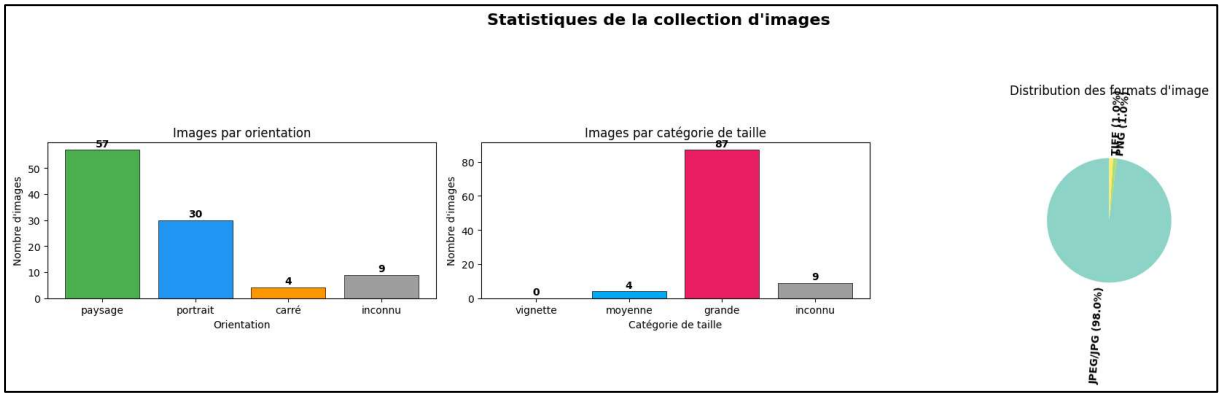


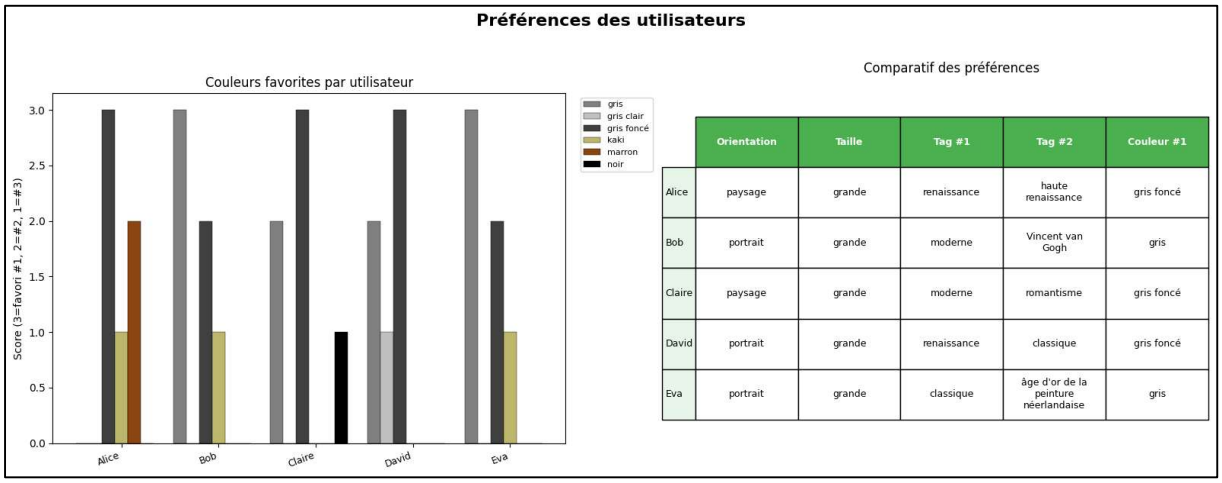
Figure « Statistiques de la collection d'images »

Les histogrammes montrent une large dominance du format paysage : 57 images, contre 30 en portrait, 4 carrées et 9 inconnues.

La taille des images est majoritairement grande (87 images), on compte 4 images moyennes, 0 en vignette et 9 inconnues.

Le diagramme de secteurs des formats indique une forte présence de JPEG/JPG (98%) avec une faible présence du PNG et du TIFE (environ 1% chacun).

Nous avions une coexistence « JPEG/jpg » qui suggérait un problème d'harmonisation dans le champ format. Ce qu'on a réglé pour le rendre « JPEG/JPG »



	Orientation	Taille	Tag #1	Tag #2	Couleur #1
Alice	paysage	grande	renaissance	haute renaissance	gris foncé
Bob	portrait	grande	moderne	Vincent van Gogh	gris
Claire	paysage	grande	moderne	romantisme	gris foncé
David	portrait	grande	renaissance	classique	gris foncé
Eva	portrait	grande	classique	âge d'or de la peinture néerlandaise	gris

Figure « Préférences des utilisateurs »

Le graphique de gauche illustre les couleurs favorites de nos utilisateurs. On observe que les différentes teintes de gris sont très souvent en tête, suivis par le kaki et plus rarement le marron ou noir selon le profil. Ces couleurs sont normales puisqu'elles sont très courantes lorsque l'on réalise des opérations sur des images et notamment des tableaux qui peuvent datés (possibilités d'avoir du noir et blanc)

Le tableau de droite résume les préférences de manière structurées :

- Orientation : 3 sur 5 de nos utilisateurs préfèrent le format portrait tandis que 2 sur 5 (Alice et Claire) préfère le format paysage.

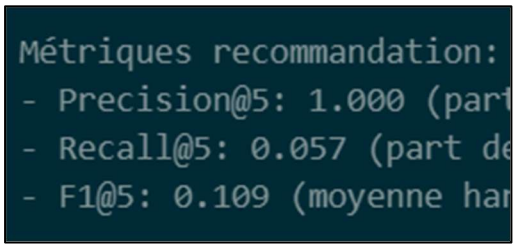
- Taille : tout le monde préfère la grande taille (ce qui est normale puisque la plupart de nos images correspondent à des grandes images).
- Couleur : l'ensemble des utilisateurs préfèrent le gris ou le gris foncé
- Tags : deux tags principaux par utilisateur sont listés (ex : mouvements/époques). Le détail exact varie selon l'utilisateur, mais on constate une récurrence de familles stylistiques (ex : « renaissance », « moderne », etc.).

- **Qualité/précision des recommandations**

Nous combinons une évaluation qualitative et quantitative.

- Qualitativement, les recommandations sont cohérentes avec les profils (tags, couleurs, orientation) et les images déjà en favoris sont exclues.
- Quantitativement, nous calculons des métriques « k » sur notre définition de pertinence : Precision@K, Recall@K et F1@K (on peut le voir dans les tests de la dernière tâche).

Sur l'exemple testé (K=5), nous obtenons Precision@5 = 1.000, Recall@5 = 0.057 et F1@5 = 0.109.



Cela indique que les recommandations proposées sont très pertinentes, mais qu'elles couvrent une part limitée de l'ensemble des images potentiellement pertinentes, ce qui est attendu avec un K faible et sans historique réel d'interactions. L'approche reste stable et explicable grâce aux raisons affichées (tags/couleurs/orientation + proximité de cluster).

- **Observations intéressantes**

La collection est dominée par des images paysage et grandes, ce qui favorise les profils ayant ces préférences et peut limiter la couverture pour des goûts moins représentés.

La normalisation des formats a été corrigée (« jpg » / « jpeg » regroupés en « JPEG/JPG »), ce qui rend les statistiques plus fiables. Sur le plan visuel, les teintes gris/gris foncé/kaki sont très présentes, ce qui peut biaiser les recommandations vers ces palettes.

Enfin, les tags issus des métadonnées (mouvements, périodes, créateurs) sont bien discriminants et améliorent l'explicabilité.

5. Limites et travaux futurs

- **Qu'est-ce qui n'a pas bien fonctionné ?**

Requêtes SPARQL : plusieurs essais ont été nécessaires pour obtenir un échantillon propre et bien licencié.

Nuage de mots : la première bibliothèque utilisé (matplotlib) ne donnait pas un rendu satisfaisant, nous avons donc utilisé la bibliothèque wordcloud et nous avons réussi à fixer ce problème.

Images très volumineuses : quelques avertissements se sont manifestés à la lecture mais sans trop de blocage.

Traitement : Impossibilité de traiter la couleur des images excédant une certaine dimension (trop grand nombre de pixels)

Difficultés de choix : entre la Renaissance et la Haute Renaissance on ne savait pas si on les différenciait ou non → On a donc choisi de les différenciés (style de peinture différent)

- **Comment pourrait-on améliorer le système ?**

Une partie des améliorations est déjà en place : approche hybride, différentes métriques...

Les prochaines améliorations pertinentes seraient donc :

- affiner la qualité sémantique des tags (hiérarchies sur les mouvements/époques...)
- ajouter des métriques complémentaires (comme nDCG@K par exemple) et des indicateurs de diversité
- réduire le biais vers les couleurs dominantes (gris/kaki) via un reranking plus diversité.

6. Conclusion

- **Résumé des réalisations**

Nous avons un projet complet : collecte et traçabilité des images, annotations (couleurs, orientation, taille, tags), profils utilisateurs clairs, et un moteur par le contenu qui donne des résultats cohérents à la lecture. Les visualisations aident à comprendre la collection et les préférences.

- **Auto-évaluation**

Le projet est cohérent, fonctionnel et compréhensible (commentaires), avec une chaîne complète allant de la collecte des données à la recommandation hybride. Les résultats sont satisfaisants, même si certaines limites subsistent (richesse des métadonnées, diversité des recommandations, etc...)

- **Bibliographie**

Wikidata (SPARQL) pour la sélection et les métadonnées (dont la licence P275),
Wikimedia Commons pour les images et les pages sources. Outils utilisés dans le notebook : pandas, matplotlib, scikit-learn (KMeans), Pillow, wordcloud.